0x1+0·1+0·1+0·0+0·0+0·0+0·0+0·-1+0·-1+0·-1

1.-

0	0	1	0	0				
0	0	1	2	1	0	1	0	-1
1	2	3	2	1	1	0	-1	
0	1	2	1	0	1	0	-1	
0	0	1	0	0				

-1	-3	0	3	1
-3	-4	0	5	3
-4	-6	0	6	4
-3	-5	0	5	3
-1	-3	0	3	1

2.- 0·1+0·1+0·1+0·0+0·0+0·0+0·0+0·-1+0·-1+1·-1 = -1 //

3.- Detecta bordes verticales al cambiar de izquierda a derecha resalta los cambios bruscos horizontales que forman una línea vertical.

Prog 2.-

1- La imagen tiene $28 \times 29 \times 3 = 2352$ elementos. Conectadas a 64 neuronas $2352 \times 64 = 150,528$ pesos //

2.- $\underset{\text{Filtro}}{3} \times \underset{\text{canal}}{3} \times 3 = 27 \times 16$ filtros $= 432$ pesos. + 1 bias por filtro

$432 + 16 = 448$ parámetros //

3.- Porque utiliza pesos compartidos y conectividad local, reduciendo la cantidad de parámetros a aprender.

Prog 3.-

1.- Un MaxPool reduce las dimensiones espaciales a la mitad.

21×29, $(21/2) = 10$ y $(29/2) = 14$ 10×14 //

2.- Los filtros de esta capa detectan patrones más complejos, estas neuronas "ven" un campo receptivo más grande de la imagen original.

3.- La mitigaría primero con Data Augmentation, ya que no obligaría a la red a memorizar características irrelevantes.

Preg 4

1.- $7 \times 7 \times 64 = 3136$

2.- $(3136 \times 32) + 32$ biases $= 100,352 + 32 =$ 100,384 parámetros

3.- Se promedia toda la cuadrícula espacial (7x7) por cada canal. Su gran ventaja es que elimina cientos de miles de parámetros en la capa Dense posterior

Preg. 5

1. $7 \times 7 \times 64 = 3136$

2.- $(3136 \times 32) + 32$ biases $= 100,352 + 32 =$ 100,384 parámetros

3.-

Preg 6

1.- Predice la clase 3 (índice 2)

2.- Está muy segura pero equivocada

3.- Será alta. Como el modelo solo asignó 5% a la clase verdadera el castigo será verdadero

Preg 6

Padding	stride	salida
valid	1	28 x 28
valid	2	14 x 14
same	1	32 x 32

- Es que la resolución espacial se destruye casi por completo.

Preg 7.

1.- Sobreviven un promedio de 16 de 32

2.- No se apagan, todas permanecen activas para usar el conocimiento de la red y dar una respuesta determinista y estable

3.- No tiene sentido. Aplicarlo a la última época solo introducirá ruido en un modelo que ya memorizó.

Preg 8

5 neuronas

1.- Esto transformará las salidas crudas en una distribución de probabilidades que suman 1

2.- las imágenes deben ser redimensionadas de 224x224 a 21x28 para coincidir con el input-shape que espera el modelo

3.- Incorporar Batch Normalization después de las convoluciones

Autoevaluación

Tema	Nota
Producto punto Kernel	4
Conteo de parámetros Conv. vs Dense	3
Efecto de apilar Conv. + Pool	2
Softmax + pérdida	1
Dropout train vs inferencia	2